Уральский федеральный университет
имени первого Президента России Б.Н.Ельцина

Программирование на Python

АНАЛИЗ ДАННЫХ. ПРАКТИКА

Андрей Скороходов

udv|group 2023

Уральский федеральный университет

Анализ данных

Анализ данных – (не строго) процесс получения из данных выводов, на основе которых можно принимать решения.

Анализ данных – преобразование массивов данных в конкурентоспособные аналитические выводы, оказывающие влияние на деловые решения и последующие действия[1]

Вид анализа	Цель	Основные понятия	Основной вопрос
Описательный (descriptive)	Количественное описание основных характеристик выборки.	Размер выборки, мода, медиана, среднее, размах, дисперсия, …	Какие у нас данные?
Разведывательный (exploratory, EDA)	Нахождение общих закономерностей, инсайтов, распределений, выбросов в данных.	Распределение, аномалия, тенденция, корреляция, гипотеза, …	Какие есть закономерности в наших данных?
Индуктивный (inferential)	Оценка генеральной совокупности на основании выборки, выявление и оценка причинно-следственных связей между переменными.	Доверительный интервал, статистическая погрешность, математическое ожидание, …	Что мы можем сказать о генеральной совокупности и насколько мы уверены в своем выводе?
Прогностический (predictive)	Предсказать поведение данных в будущем на основании их прошлых значений.	Прогноз, метрики качества, …	Как будут вести себя данные в будущем?
Причинно-следственный (causal)	Объяснение с точки зрения данных причин возникновения события (следствия).	Причина, следствие, симптом, …	Что является причиной такого поведения данных, а что следствием?

[1] Карл Андерсон. Аналитическая культура. М.: Манн, Иванов и Фербер, 2017.

Уральский федеральный университет

Pandas

Pandas – библиотека для обработки и анализа данных в Python.

import pandas as pd

Основные типы данных:

- **Series** – одномерный массив, *df = pd.Series()*
- **DataFrame** – таблица (двумерный массив), *df = pd.DataFrame()*

Примеры методов для DataFrame (для Series – аналогично):

- *df = pd.DataFrame(data, index=index, …)* – создание датафрейма
- *df.shape* – размер датафрейма
- *df.info()* – получение информации о датафрейме
- *df.copy()* – копирование датафрейма
- *df = pd.read_csv(filename)* – создание датафрейма из csv файла
- *df.head(n), df.tail(n)* – возвращение n первых/последних строк
- *df.sort_values([columns])* – сортировка датафрейма
- *df.groupby([columns])[column].agg()* – группировка данных по columns
- *df.apply(function)* – применение функции к столбцам таблицы

```
df = pd.read_csv(filename)
df.head(5)
```

```
CPU times: total: 3.03 s
Wall time: 3.03 s
```

columns

	Timestamp	FIT101	LIT101	MV101	P101	P102	AIT201	A
0	22/12/2015 4:30:00 PM	0.0	124.3135	1	1	1	251.9226	8.31
1	22/12/2015 4:30:01 PM	0.0	124.3920	1	1	1	251.9226	8.31
2	22/12/2015 4:30:02 PM	0.0	124.4705	1	1	1	251.9226	8.31
3	22/12/2015 4:30:03 PM	0.0	124.6668	1	1	1	251.9226	8.31
4	22/12/2015 4:30:04 PM	0.0	124.5098	1	1	1	251.9226	8.31

indexes

5 rows × 53 columns

```
df.info(verbose=False)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 495000 entries, 0 to 494999
Columns: 53 entries,  Timestamp to Normal/Attack
dtypes: float64(25), int64(26), object(2)
memory usage: 200.2+ MB
```

```
df.describe().T
```

	count	mean	std	min	25%	
FIT101	495000.0	1.850517	1.132519	0.000000	0.000000	
LIT101	495000.0	587.532773	121.666482	120.623700	508.441000	5

Уральский федеральный университет

Pandas. Создание DataFrame

- **Из файла:** pd.read_*<формат файла>*. Поддерживаются csv, excel-таблицы, URL-таблицы, pickle, json, html, sql, parquet и др. форматы:

  df = pd.read_csv(*<имя файла>, <параметры>*)
- **Из словаря:** *df* = pd.DataFrame(*some_dict*), *df* = pd.DataFrame.from_dict(*some_dict*)
- **Из списка:** *df* = pd.DataFrame(*some_list*)
- **Пустой датафрейм:** *df* = pd.DataFrame()
- **Пустой датафрейм с индексами:** *df* = pd.DataFrame(index=*some_list*)
- **Пустой датафрейм с колонками:** *df* = pd.DataFrame(columns=*some_list*)
- И другие способы…

```
pd.DataFrame({'column1': [11, 21, 31],
              'column2': [12, 22, 32],
              'column3': [13, 23, 33]})
```

	column1	column2	column3
0	11	12	13
1	21	22	23
2	31	32	33

```
pd.DataFrame([[11, 12, 13],
              [21, 22, 23],
              [31, 32, 33]],
             columns=['col1','col2','col3'])
```

	col1	col2	col3
0	11	12	13
1	21	22	23
2	31	32	33

С Series создание объекта идентично DataFrame, разница лишь в том, что Series – одномерный массив и данные на входе нужны соответствующие.

```
pd.Series(range(5),
          index=['id1','id2','id3','id4','id5'])
```

```
id1    0
id2    1
id3    2
id4    3
id5    4
dtype: int64
```

Уральский федеральный университет

Pandas. Обращение к элементам датафрейма

Обращение к элементам датафрейма возможно:

- **По целочисленному индексу:** df.iloc[*<индекс строки>, <индекс колонки>*]
- **По текстовой метке:** df.loc[*<метка строки>, <метка колонки>*]
- Можно обращаться и без специального указания на тип запроса:

df[*<индекс строки>, <метка колонки>*]

Возможны манипуляции с отдельными строками или колонками:

```
df['column2']
```

```
row0    61
row1    17
row2    77
row3     5
row4    17
Name: column2, dtype: int64
```

```
df.loc['row1']
```

```
column0    64
column1    17
column2    17
column3     4
column4    71
Name: row1, dtype: int64
```

В Pandas реализована поддержка слайсов (как в списках или кортежах):

```
df.loc['row2':'row3', 'column1':'column3']
```

	column1	column2	column3
row2	35	77	70
row3	90	5	94

```
df[2:3]['column1']
```

```
row2    35
Name: column1, dtype: int64
```

```
import random

dict1 = {
    f"column{i}": [random.randint(0,100) for i in range(5)] for i in range(5)
}

df = pd.DataFrame(dict1, index=[f"row{i}" for i in range(5)])
df
```

	0 column0	1 column1	2 column2	3 column3	column4
0 **row0**	1	61	61	19	0
1 **row1**	64	17	17	4	71
2 **row2**	43	35	77	70	11
row3	96	90	5	94	71
3 **row4**	26	94	17	57	59

```
df.iloc[1,1], df.loc['row1','column1']
```

```
(17, 17)
```

Уральский федеральный университет

Pandas. Фильтрация данных

Для выбора значений датафрейма, подходящих под условие, можно:

- Использовать **индексы**

```
df[(df['column1']>40) & (df['column3']<60)]
```

	column0	column1	column2	column3	column4
row0	1	61	61	19	0
row4	26	94	17	57	59

В этом случае при перечислении условий каждое условие заключается в (), а между скобками ставится операнд (&, |). Каждое условие возвращает на выходе Series с булевыми значениями, выражение внутри df[ ] должно иметь то же количество строк, что и фильтруемый датафрейм.

```
df['column3']<60
```

```
row0     True
row1     True
row2    False
row3    False
row4     True
Name: column3, dtype: bool
```

```
df['column1']>40
```

```
row0     True
row1    False
row2    False
row3     True
row4     True
Name: column1, dtype: bool
```

- Использовать **query**

```
df.query("column1 > 40 and column3 < 60")
```

	column0	column1	column2	column3	column4
row0	1	61	61	19	0
row4	26	94	17	57	59

Исходный датафрейм

```
df
```

	column0	column1	column2	column3	column4
row0	1	61	61	19	0
row1	64	17	17	4	71
row2	43	35	77	70	11
row3	96	90	5	94	71
row4	26	94	17	57	59

Уральский федеральный университет

Pandas. Изменение/добавление элементов

Для изменения элемента датафрейма следует обратиться к нему через loc или iloc:

```
df.loc['row1', 'column1'] = 10
df.iloc[1, 2] = 20
df.loc['row1', 'column1'], df.iloc[1, 2]
```

```
(10, 20)
```

Можно добавлять новую колонку/строку с нуля или на основании значений в другой колонке/строке:

Исходный датафрейм

	column0	column1	column2	column3	column4
row0	0	10	20	30	40
row1	1	11	21	31	41
row2	2	12	22	32	42
row3	3	13	23	33	43
row4	4	14	24	34	44

Добавление колонки

```
df['column5'] = df['column4'] * 2
df['column6'] = range(df.shape[0])
df['column7'] = 99
df
```

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0	10	20	30	40	80	0	99
row1	1	10	20	31	41	82	1	99
row2	2	12	22	32	42	84	2	99
row3	3	13	23	33	43	86	3	99
row4	4	14	24	34	44	88	4	99

Добавление строки

```
df.loc['row5'] = df.loc['row4'] + 10
df.loc['row6'] = range(df.shape[1])
df.loc['row6'] = 99
df
```

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0	10	20	30	40	80	0	99
row1	1	10	20	31	41	82	1	99
row2	2	12	22	32	42	84	2	99
row3	3	13	23	33	43	86	3	99
row4	4	14	24	34	44	88	4	99
row5	14	24	34	44	54	98	14	109
row6	99	99	99	99	99	99	99	99

Уральский федеральный университет

Pandas. Удаление элементов, параметр axis

Для удаления строки или колонки можно воспользоваться методом drop(). Здесь и далее для методов DataFrame параметр axis=1 подразумевает, что операция относится к колонкам, а axis=0 – к строкам:

```
df.drop(['column1', 'column2'], axis=1)
df.drop(['row2', 'row3'])
```

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0	10	20	30	40	80	0	99
row1	1	10	20	31	41	82	1	99
row4	4	14	24	34	44	88	4	99
row5	14	24	34	44	54	98	14	109
row6	99	99	99	99	99	99	99	99

Исходный датафрейм

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0	10	20	30	40	80	0	99
row1	1	10	20	31	41	82	1	99
row2	2	12	22	32	42	84	2	99
row3	3	13	23	33	43	86	3	99
row4	4	14	24	34	44	88	4	99
row5	14	24	34	44	54	98	14	109
row6	99	99	99	99	99	99	99	99

Для удаления несуществующих (NaN) значений следует использовать метод dropna():

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0.0	10	20	30	40	80.0	0.0	99.0
row1	1.0	10	20	31	41	82.0	NaN	99.0
row2	2.0	12	22	32	42	84.0	2.0	99.0
row3	3.0	13	23	33	43	86.0	3.0	99.0
row4	4.0	14	24	34	44	88.0	4.0	NaN
row5	14.0	24	34	44	54	98.0	NaN	109.0
row6	NaN	99	99	99	99	NaN	99.0	99.0

```
df.dropna()
```

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0.0	10	20	30	40	80.0	0.0	99.0
row2	2.0	12	22	32	42	84.0	2.0	99.0
row3	3.0	13	23	33	43	86.0	3.0	99.0

В зависимости от установленных параметров метод dropna может удалять строки (axis=0) или колонки (axis=1) если все (how='all') или хотя бы одно (how='any') значение будет NaN. Также можно искать NaN только в конкретных колонках (subset=[…])

Уральский федеральный университет

Pandas. Объединение датафреймов

Для объединения датафреймов (или Series и датафрейма) можно применять функцию pd.concat([df1, df2, …], axis=…):

df_A

	column0	column1	column2
row0	A0	A10	A20
row1	A1	A11	A21
row2	A2	A12	A22

df_B

	column0	column1	column2	column3
row0	B0	B10	B20	B30
row1	B1	B11	B21	B31
row2	B2	B12	B22	B32
row3	B3	B13	B23	B33

pd.concat()

```
pd.concat([df_A, df_B])
```

	column0	column1	column2	column3
row0	A0	A10	A20	NaN
row1	A1	A11	A21	NaN
row2	A2	A12	A22	NaN
row0	B0	B10	B20	B30
row1	B1	B11	B21	B31
row2	B2	B12	B22	B32
row3	B3	B13	B23	B33

```
pd.concat([df_A, df_B], axis=1)
```

	column0	column1	column2	column0	column1	column2	column3
row0	A0	A10	A20	B0	B10	B20	B30
row1	A1	A11	A21	B1	B11	B21	B31
row2	A2	A12	A22	B2	B12	B22	B32
row3	NaN	NaN	NaN	B3	B13	B23	B33

df.merge()

```
df_A.merge(df_B, left_index=True, right_index=True)
```

	column0_x	column1_x	column2_x	column0_y	column1_y	column2_y	column3
row0	A0	A10	A20	B0	B10	B20	B30
row1	A1	A11	A21	B1	B11	B21	B31
row2	A2	A12	A22	B2	B12	B22	B32

Для объединения по заданным условиям лучше применять функцию df1.merge(df2,…).

merge позволяет выбирать условия объединения (по индексам, по колонкам), тип объединения (inner, outer, right, left, …) и другие опции.

Уральский федеральный университет

Pandas. Изменение датафреймов. Функция apply()

Функция df.apply позволяет применить произвольную функцию к отдельным строкам (axis=0)/колонкам (axis=1) датафрейма.

```
df[['column1', 'column2']].apply(lambda x: x%2)
```

	column1	column2
row0	0	0
row1	0	0
row2	0	0
row3	1	1
row4	0	0
row5	0	0
row6	1	1

Исходный датафрейм

	column0	column1	column2	column3	column4	column5	column6	column7
row0	0	10	20	30	40	80	0	99
row1	1	10	20	31	41	82	1	99
row2	2	12	22	32	42	84	2	99
row3	3	13	23	33	43	86	3	99
row4	4	14	24	34	44	88	4	99
row5	14	24	34	44	54	98	14	109
row6	99	99	99	99	99	99	99	99

Для применения функции ко всему датафрейму можно применить функцию df.applymap()

К колонкам можно применять собственные функции, аргументы передаются через параметр args=:

```
def some_function(element_df, a):
    return element_df - a

df.apply(some_function, args=(10,))
```

	column0	column1	column2	column3	column4	column5	column6	column7
row0	-10.0	0	10	20	30	70.0	-10.0	89.0
row1	-9.0	0	10	21	31	72.0	NaN	89.0
row2	-8.0	2	12	22	32	74.0	-8.0	89.0

Уральский федеральный университет

Pandas. Сортировка данных

Для сортировки по определенной колонке следует применять функцию df.sort_values(<колонка>)

```
df.sort_values('column6', ascending=False)
```

	column0	column1	column2	column3	column4	column5	column6	column7
row6	NaN	99	99	99	99	NaN	99.0	99.0
row4	4.0	14	24	34	44	88.0	4.0	NaN
row3	3.0	13	23	33	43	86.0	3.0	99.0
row2	2.0	12	22	32	42	84.0	2.0	99.0
row0	0.0	10	20	30	40	80.0	0.0	99.0
row1	1.0	10	20	31	41	82.0	NaN	99.0
row5	14.0	24	34	44	54	98.0	NaN	109.0

Для по сортировки по индексу следует применять функцию df.sort_index()

```
df.sort_index(ascending=False)
```

	column0	column1	column2	column3	column4	column5	column6	column7
row6	NaN	99	99	99	99	NaN	99.0	99.0
row5	14.0	24	34	44	54	98.0	NaN	109.0
row4	4.0	14	24	34	44	88.0	4.0	NaN
row3	3.0	13	23	33	43	86.0	3.0	99.0
row2	2.0	12	22	32	42	84.0	2.0	99.0
row1	1.0	10	20	31	41	82.0	NaN	99.0
row0	0.0	10	20	30	40	80.0	0.0	99.0

Исходный датафрейм

	column0	column1	column2	column3	column4	column5	column6
row0	1	61	61	19	0	0	0
row1	64	10	20	4	71	142	1
row2	43	35	77	70	11	22	2
row3	96	90	5	94	71	142	3
row4	26	94	17	57	59	118	4
row5	36	104	27	67	69	128	14
row6	0	1	2	3	4	5	6

Уральский федеральный университет

Pandas. Статистика датафрейма

Pandas позволяет получить множество статистик из датафрейма и отлично подходит для описательной аналитики.

Для примера мы возьмем датасет с информацией о пассажирах Титаника.

```
df.head(5)
```

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

Сводная статистика

```
df.describe() # описание всего датасета
```

	survived	pclass	age	sibsp	parch	fare
count	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

Статистика по колонкам/строкам

```
df['age'].mean(), df['age'].min(), df['age'].max()
```

```
(29.69911764705882, 0.42, 80.0)
```

```
df['pclass'].unique()
```

```
array([3, 1, 2], dtype=int64)
```

```
df['pclass'].nunique()
```

```
3
```

```
df['pclass'].value_counts()
```

```
pclass
3    491
1    216
2    184
Name: count, dtype: int64
```

Уральский федеральный университет

Pandas. Группировка данных

Для группировки данных в pandas используется функция groupby():

df.groupby([*<колонки для агрегации>*])[*<колонки для подсчета>*].*<агрегирующая функция>*()

Стандартные агрегирующие функции: 'sum', 'mean', 'median', 'min', 'max', 'std', 'var', 'mad', 'prod'.

Можно применять к разным колонкам разные агрегирующие функции.

Можно написать собственную агрегирующую функцию.

Исходный датафрейм

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who
0	0	3	male	22.0	1	0	7.2500	S	Third	man
1	1	1	female	38.0	1	0	71.2833	C	First	woman
2	1	3	female	26.0	0	0	7.9250	S	Third	woman
3	1	1	female	35.0	1	0	53.1000	S	First	woman
4	0	3	male	35.0	0	0	8.0500	S	Third	man

```
df.groupby('pclass')[['fare', 'age']].mean()
```

pclass	fare	age
1	84.154687	38.233441
2	20.662183	29.877630
3	13.675550	25.140620

```
agg_func = {'fare': ['describe']}
df.groupby(['pclass']).agg(agg_func).round(2)
```

	fare							
	describe							
	count	mean	std	min	25%	50%	75%	max
pclass								
1	216.0	84.15	78.38	0.0	30.92	60.29	93.5	512.33
2	184.0	20.66	13.42	0.0	13.00	14.25	26.0	73.50
3	491.0	13.68	11.78	0.0	7.75	8.05	15.5	69.55

```
(df
 .groupby(['pclass', 'who'])[['fare', 'age']]
 .agg(['min', 'mean', 'max'])
 .round(2)
)
```

		fare			age		
		min	mean	max	min	mean	max
pclass	who						
1	child	81.86	139.38	211.34	0.92	7.82	15.0
	man	0.00	65.95	512.33	17.00	42.38	80.0
	woman	25.93	104.32	512.33	16.00	35.50	63.0
2	child	14.50	28.32	41.58	0.67	4.54	14.0
	man	0.00	19.05	73.50	16.00	33.59	70.0
	woman	10.50	20.87	65.00	17.00	32.18	57.0
3	child	7.22	23.22	46.90	0.42	6.82	15.0
	man	0.00	11.34	69.55	16.00	29.00	74.0
	woman	6.75	15.35	69.55	16.00	27.85	63.0

Подробное руководство по группировке и агрегированию в pandas

Уральский федеральный университет

Pandas. Операции с датой и временем

В Pandas существует специальные форматы для времени и даты – Timestamp, Timedelta и datetime64[ns]. Преобразование к ним выполняется через функцию pd.to_datetime(<строка>, <формат>) или через pd.to_timedelta(<строка>), если речь идет о разнице во времени. После преобразования в нужный формат становятся доступными операции с этими значениями как со временем (например, вычитание или ресэмплирование), а также получение дополнительных данных через специальный форматтер **dt**, например дня, даты или часа.

Исходный датафрейм

	Timestamp	FIT101	LIT101	MV101	P101	AIT201	AIT202	AIT203	FIT201
0	2015-12-22 04:30:00	0.0	124.3135	1	1	251.9226	8.313446	312.7916	0.000000
1	2015-12-22 04:30:01	0.0	124.3920	1	1	251.9226	8.313446	312.7916	0.000000
2	2015-12-22 04:30:02	0.0	124.4705	1	1	251.9226	8.313446	312.7916	0.000000
3	2015-12-22 04:30:03	0.0	124.6668	1	1	251.9226	8.313446	312.7916	0.000000
4	2015-12-22 04:30:04	0.0	124.5098	1	1	251.9226	8.313446	312.7916	0.000000

Дата

```
df1[' Timestamp'].dt.date
```

```
0         2015-12-22
1         2015-12-22
2         2015-12-22
3         2015-12-22
4         2015-12-22
             ...
494995    2015-12-28
494996    2015-12-28
494997    2015-12-28
494998    2015-12-28
494999    2015-12-28
Name:  Timestamp, Length: 495000,
```

День

```
df1[' Timestamp'].dt.day
```

```
0         22
1         22
2         22
3         22
4         22
          ..
494995    28
494996    28
494997    28
494998    28
494999    28
Name:  Timestamp, Length: 495000,
```

Разница по времени

```
df1[' Timestamp'].diff()
```

```
0                    NaT
1         0 days 00:00:01
2         0 days 00:00:01
3         0 days 00:00:01
4         0 days 00:00:01
                  ...
494995    0 days 00:00:01
494996    0 days 00:00:01
494997    0 days 00:00:01
494998    0 days 00:00:01
494999    0 days 00:00:01
Name:  Timestamp, Length: 495000,
```

Увеличение даты на 1 день

```
df1[' Timestamp'] + pd.to_timedelta('1D')
```

```
0         2015-12-23 04:30:00
1         2015-12-23 04:30:01
2         2015-12-23 04:30:02
3         2015-12-23 04:30:03
4         2015-12-23 04:30:04
                  ...
494995    2015-12-29 12:59:55
494996    2015-12-29 12:59:56
494997    2015-12-29 12:59:57
494998    2015-12-29 12:59:58
494999    2015-12-29 12:59:59
Name:  Timestamp, Length: 495000, dtype:
```

Уральский федеральный университет

Pandas. Операции со строками

В Pandas существует специальный форматтер для удобной работы со строками: **str**.

При его использовании становятся доступными все основные функции работы со строками.

Исходный датафрейм

```
df1
```

	sex	class	who	embark_town
0	male	Third	man	Southampton
1	female	First	woman	Cherbourg
2	female	Third	woman	Southampton
3	female	First	woman	Southampton
4	male	Third	man	Southampton

contains (содержит значение)

```
df1[df1['sex'].str.contains('fem')]
```

	sex	class	who	embark_town
1	female	First	woman	Cherbourg
2	female	Third	woman	Southampton
3	female	First	woman	Southampton
8	female	Third	woman	Southampton
9	female	Second	child	Cherbourg

upper
(преобразование регистров)

```
df1['sex'].str.upper()
```

```
0        MALE
1      FEMALE
2      FEMALE
3      FEMALE
4        MALE
       ...
```

count
(подсчет символов)

```
df1['sex'].str.count('e')
```

```
0    1
1    2
2    2
3    2
4    1
```

Можно выполнять быстрое преобразование из одного текста в другой:

```
df1['new_feature'] = df['sex'].str.replace('e','*') + "_" + df['class'].str.lower()
df1
```

	sex	class	who	embark_town	pclass	new_feature
0	male	Third	man	Southampton	3	mal*_third
1	female	First	woman	Cherbourg	1	f*mal*_first
2	female	Third	woman	Southampton	3	f*mal*_third
3	female	First	woman	Southampton	1	f*mal*_first
4	male	Third	man	Southampton	3	mal*_third

Уральский федеральный университет

Pandas. Сохранение датафрейма

Сохранять данные в файл в pandas очень просто: **df.to_*<нужный формат>*(*<имя файла>*, *<опции>*)**.

Поддерживаются все те же форматы, что и при загрузке данных: csv, excel, json, parquet, pickle и т.п.

```
df.to_csv(filename, index=False)
```

```
%%time
df = pd.read_csv(filename)
df.head(5)
```

```
CPU times: total: 2.31 s
Wall time: 2.33 s
```

	Timestamp	FIT101	LIT101	MV101	P101	P102	AIT201	AIT202
0	22/12/2015 4:30:00 PM	0.0	124.3135	1	1	1	251.9226	8.313446
1	22/12/2015 4:30:01 PM	0.0	124.3920	1	1	1	251.9226	8.313446
2	22/12/2015 4:30:02 PM	0.0	124.4705	1	1	1	251.9226	8.313446
3	22/12/2015 4:30:03 PM	0.0	124.6668	1	1	1	251.9226	8.313446
4	22/12/2015 4:30:04 PM	0.0	124.5098	1	1	1	251.9226	8.313446

Уральский федеральный университет

SciPy

SciPy – библиотека для научных и инженерных расчетов в Python.

from scipy import <имя пакета>

Основные пакеты библиотеки:

- cluster – кластерный анализ
- constants – различные константы (физические и математические)
- *fftpack – быстрое п*реобразование Фурье
- *integrate* – интегральные уравнения и диффуры
- *interpolate* – интерполяция и сглаживание
- *io* – ввод/вывод
- *linalg –* линейная алгебра
- *ndimage* – обработка изображений
- *odr* – метод ортогональных расстояний
- *optimize* – оптимизация и численное решение уравнений
- *signal* – обработка сигналов
- *sparse* – разреженные матрицы
- *spatial* – разреженные структуры данных и алгоритмы
- *special* – специальные функции
- *stats* – статистические распределения и функции

Уральский федеральный университет

SciPy. Примеры применения

Тригонометрические и экспоненциальные функции

```
from scipy import special
a = special.exp10(3)
print(a)
b = special.exp2(3)
print(b)
c = special.sindg(90)
print(c)
d = special.cosdg(45)
print(f"{d:.4f}")
```

```
1000.0
8.0
1.0
0.7071
```

Частотно-модулированный сигнал

```
from scipy.signal import chirp
t = np.linspace(2, 10, 500)
w = chirp(t, f0=4, f1=2, t1=5, method='linear')
plt.figure(figsize=(2,2))
plt.plot(t, w)
plt.show()
```

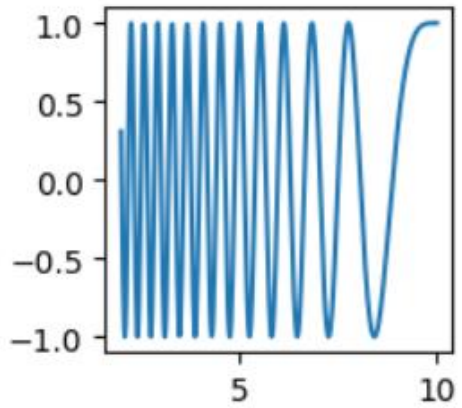

Операции с матрицами

```
from scipy import linalg
A = np.array([[10,11], [21,30]])
print(linalg.det(A)) # определитель
linalg.inv(A) # обратная матрица
```

```
69.0
array([[ 0.43478261, -0.15942029],
       [-0.30434783,  0.14492754]])
```

Интерполяция

```
import matplotlib.pyplot as plt
from scipy import interpolate

x = np.arange(0, 20)
y = np.exp(x/3.0)
f = interpolate.interp1d(x, y)
x1 = np.arange(2, 18)
y1 = f(x1)
plt.figure(figsize=(2,2))
plt.plot(x, y, x1, y1)
plt.show()
```

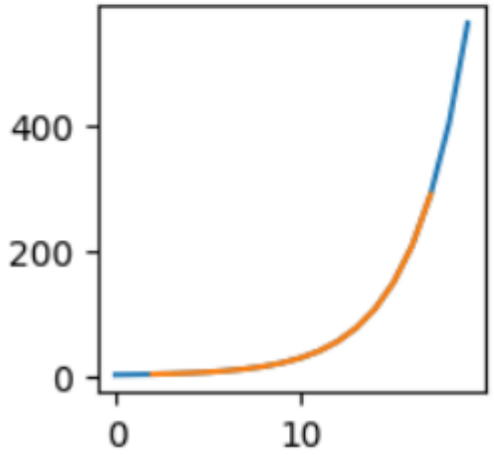

NumPy

Numpy – библиотека для работы с многомерными массивами и матрицами.

import numpy as np

Основной тип данных: **numpy.ndarray**

Примеры методов работы с массивом:

- *arr = np.array([1,2],[3,4])* – создание двумерного массива
- *arr.ndim* – число измерений массива
- *arr.shape* – размеры массива
- *arr.size* – количество элементов в массиве

Numpy позволяет автоматически создавать различные массивы.

```
import numpy as np

a = np.array([[1,2], [3,4]])
print(type(a))
print(a)
print('ndim: \t', a.ndim)
print('shape: \t', a.shape)
print('size: \t', a.size)
```

```
<class 'numpy.ndarray'>
[[1 2]
 [3 4]]
ndim:    2
shape:   (2, 2)
size:    4
```

Матрица с нулевыми эл-тами

```
np.zeros((5, 4))
```

```
array([[0., 0., 0., 0.],
       [0., 0., 0., 0.],
       [0., 0., 0., 0.],
       [0., 0., 0., 0.],
       [0., 0., 0., 0.]])
```

Матрица с единичными эл-тами

```
np.ones((5, 4))
```

```
array([[1., 1., 1., 1.],
       [1., 1., 1., 1.],
       [1., 1., 1., 1.],
       [1., 1., 1., 1.],
       [1., 1., 1., 1.]])
```

Единичная матрица

```
np.eye(5)
```

```
array([[1., 0., 0., 0., 0.],
       [0., 1., 0., 0., 0.],
       [0., 0., 1., 0., 0.],
       [0., 0., 0., 1., 0.],
       [0., 0., 0., 0., 1.]])
```

Многомерный массив

```
np.ones((2,2,2))
```

```
array([[[1., 1.],
        [1., 1.]],

       [[1., 1.],
        [1., 1.]]])
```

Также можно воспользоваться функцией np.empty() для создания пустого массива, заполненного остатками данных в памяти

Уральский федеральный университет

NumPy. Примеры работы

Генерация последовательностей при помощи np.arange()

(возможно использование np.random.random(), np.linspace()):

```
arr = np.arange(1, 10)
arr
```

```
array([1, 2, 3, 4, 5, 6, 7, 8, 9])
```

Изменение размерности массива при помощи arr.reshape():

```
arr = arr.reshape(3,3)
arr
```

```
array([[1, 2, 3],
       [4, 5, 6],
       [7, 8, 9]])
```

Приведение массива к плоскому виду при помощи arr.flat:

```
np.array(arr.flat)
```

```
array([1, 2, 3, 4, 5, 6, 7, 8, 9])
```

Доступ к элементам массива осуществляется по индексам, поддерживаются слайсы.

```
print("1 элемент:",arr[1,2])
print("Слайс:\n",arr[:2, :2])
print("Другой слайс:\n", arr[:2, :])
```

```
1 элемент: 6
Слайс:
 [[1 2]
 [4 5]]
Другой слайс:
 [[1 2 3]
 [4 5 6]]
```

Уральский федеральный университет

NumPy. Операции над массивами

Для массивов поддерживаются все стандартные операции: сложение, вычитание, умножение и деление, скалярное произведение.

Исходный массив

```
arr1 = np.arange(1,10).reshape(3,3)
arr2 = np.arange(0,12).reshape(3,4)
print(arr1)
print(arr2)
```

```
[[1 2 3]
 [4 5 6]
 [7 8 9]]
[[ 0  1  2  3]
 [ 4  5  6  7]
 [ 8  9 10 11]]
```

Сложение и вычитание

```
arr1 + 10
```

```
array([[11, 12, 13],
       [14, 15, 16],
       [17, 18, 19]])
```

```
arr1 - 10
```

```
array([[-9, -8, -7],
       [-6, -5, -4],
       [-3, -2, -1]])
```

```
arr1 + arr2[:,:3]
```

```
array([[ 1,  3,  5],
       [ 8, 10, 12],
       [15, 17, 19]])
```

Умножение и деление

```
arr1 / 10
```

```
array([[0.1, 0.2, 0.3],
       [0.4, 0.5, 0.6],
       [0.7, 0.8, 0.9]])
```

```
arr2 * 2
```

```
array([[ 0,  2,  4,  6],
       [ 8, 10, 12, 14],
       [16, 18, 20, 22]])
```

Скалярное произведение

```
arr1.dot(arr2)
```

```
array([[ 32,  38,  44,  50],
       [ 68,  83,  98, 113],
       [104, 128, 152, 176]])
```

Другие преобразования

```
np.cos(arr1)
```

```
array([[ 0.54030231, -0.41614684, -0.9899925 ],
       [-0.65364362,  0.28366219,  0.96017029],
       [ 0.75390225, -0.14550003, -0.91113026]])
```

Уральский федеральный университет

NumPy. Статистики

Для массивов поддерживается стандартный набор статистик:

- максимальный (np.max) и минимальный (np.min) элементы
- дисперсия (np.var) и стандартное отклонение (np.std)
- среднее значение (np.mean) и медиана (np.median)
- суммы (np.sum) и т.п.

Операции могут производиться как над всем массивом, так и отдельно по его осям (axis=0 или axis=1)

```
arr2
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
np.sum(arr2)
```

```
66
```

```
np.sum(arr2, axis=0)
```

```
array([12, 15, 18, 21])
```

```
np.sum(arr2, axis=1)
```

```
array([ 6, 22, 38])
```

```
np.mean(arr2)
```

```
5.5
```

```
np.var(arr2) # дисперсия
```

```
11.916666666666666
```

```
np.std(arr2) # ст.отклонение
```

```
3.452052529534663
```

Уральский федеральный университет

NumPy. Объединение и разбиение массивов

Для **объединения** массивов существуют методы:

- np.hstack() – объединение по горизонтальной оси
- np.vstack() – объединение по вертикальной оси
- np.column_stack() – объединение одномерных массивов как столбцов
- np.row_stack() – объединение одномерных массивов как строк

Для **разбиения** массивов аналогично:

- np.hsplit() – разбиение вдоль горизонтальной оси
- np.vsplit() – разбиение вдоль вертикальной оси

```
arr1
```

```
array([[1, 2, 3],
       [4, 5, 6],
       [7, 8, 9]])
```

```
arr2
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
np.hstack((arr1, arr2))
```

```
array([[ 1,  2,  3,  0,  1,  2,  3],
       [ 4,  5,  6,  4,  5,  6,  7],
       [ 7,  8,  9,  8,  9, 10, 11]])
```

```
np.vstack((arr1, arr2[:,:3]))
```

```
array([[ 1,  2,  3],
       [ 4,  5,  6],
       [ 7,  8,  9],
       [ 0,  1,  2],
       [ 4,  5,  6],
       [ 8,  9, 10]])
```

```
np.hsplit(arr2, 2)
```

```
[array([[0, 1],
        [4, 5],
        [8, 9]]),
 array([[ 2,  3],
        [ 6,  7],
        [10, 11]])]
```

Уральский федеральный университет

Matplotlib

Matplotlib – пакет для визуализации данных в Python, pyplot – модуль matplotlib, который предоставляет интерфейс к созданным при помощи matplotlib объектам.

```
import matplotlib.pyplot as plt
```

Основные методы:

- *plt.plot(x, y)* – построить линейный график по точкам из списков *x* и *y*
- *plt.show()* – вывод визуализированных данных
- *plt.xlabel('Ось x'), plt.ylabel('Ось y')* – подписи к осям графика
- *plt.title('Название графика')* – название графика
- *plt.legend()* – добавление к графику легенды

Кроме основного метода *plot*, который отображает данные в виде линейного графика, доступны:

- *plt.scatter(x, y)* – диаграмма рассеяния
- *plt.bar(x, y)* – столбчатая диаграмма
- *plt.pie(values)* – круговая диаграмма
- *plt.boxplot(x)* – диаграмма распределения
- И множество других…

Диаграммы обычно можно комбинировать на одном графике.

```
x = np.array(df['age'].dropna())
plt.figure(figsize=(2,5))
plt.boxplot(x)
plt.title('Распределение возраста')
plt.show()
```

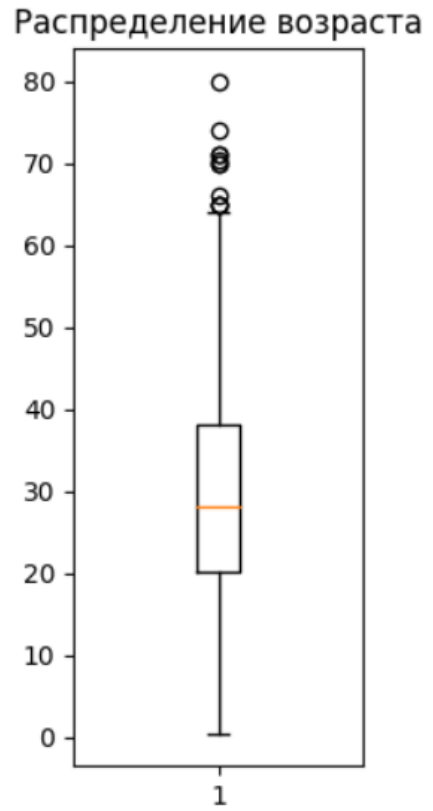

Matplotlib. Примеры

Для демонстрации работы matplotlib будем использовать датасет от Титаника.

```
df.head(5)
```

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

```
size = 200
age = np.array(df['age'][:size])
fare = np.array(df['fare'][:size])

plt.figure(figsize=(20,5)) # Изменение размера области построения графика
plt.title('Пример названия графика') # изменение заголовка
plt.plot(range(size),age, label='age', color='green') # линейный график
plt.scatter(range(size), fare, label='fare', color='blue') # точечный график
plt.xlabel('Номер пассажира') # подпись оси X
plt.ylabel('возраст/стоимость билета') # подпись оси Y
plt.legend() # отобразить легенду
plt.grid() # отобразить сетку
plt.show() # скрыть служебные сообщения
```

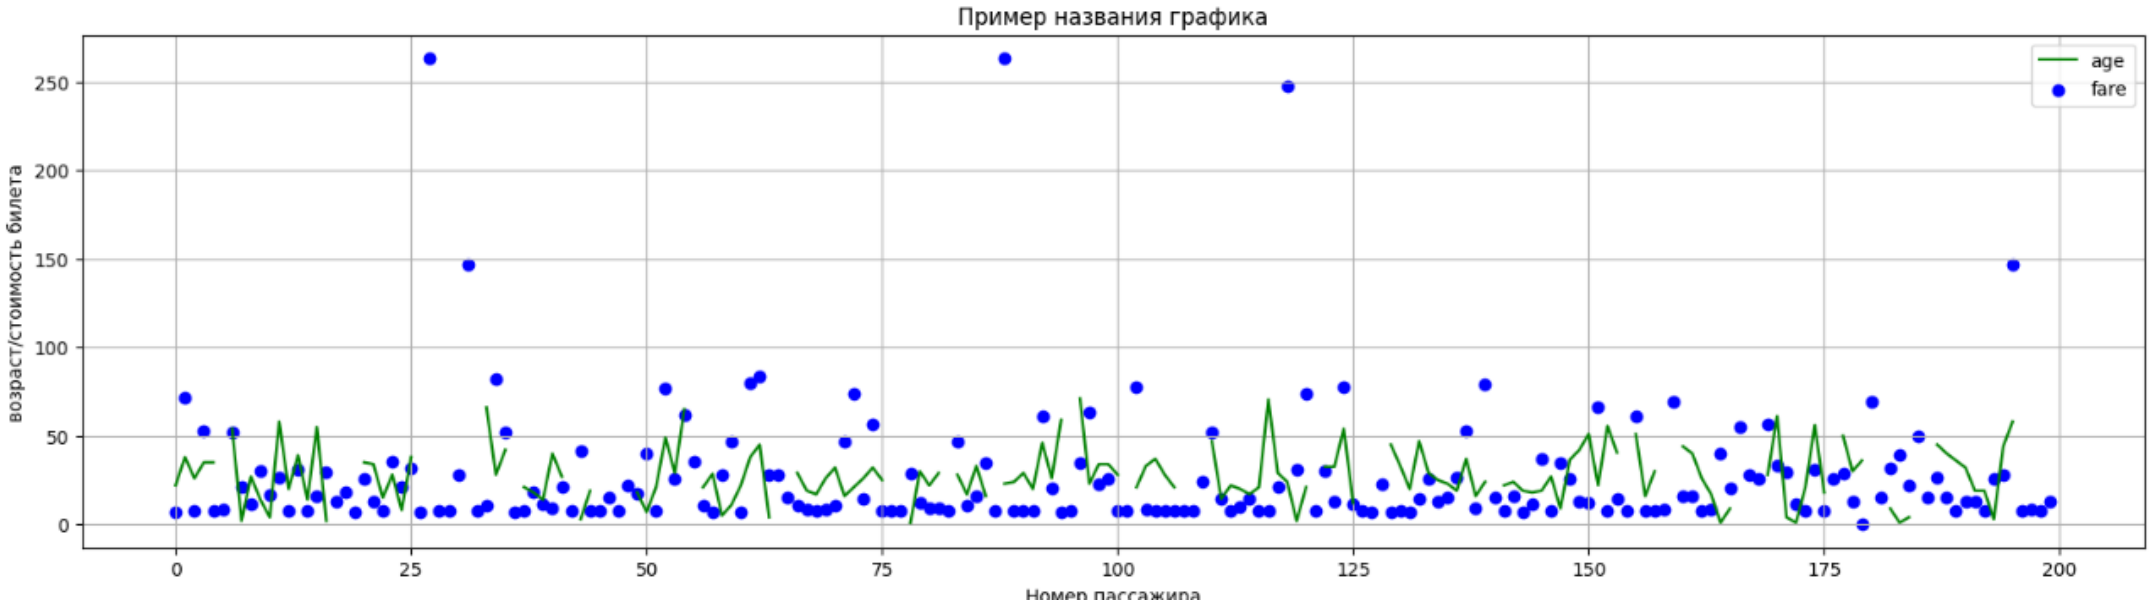

Уральский федеральный университет

Matplotlib. Subplots

```
plt.figure(figsize=(10,3))

plt.subplot(1, 3, 1) # (кол-во строк,кол-во столбцов,ячейка)
plt.hist(df['age'], bins=50)
plt.title('age histogram')

plt.subplot(1, 3, 2)
sex = df.groupby('sex')[['sibsp', 'survived']].sum()
plt.bar([0.1, 1], sex.loc['male'], 0.2, label='male')
plt.bar([0.3, 1.2], sex.loc['female'], 0.2, label='female')
plt.xticks([0.2, 1.1], ['sibsp','survived'])
plt.title('survived/sibsp bar')
plt.legend()

plt.subplot(1, 3, 3)
pclass = df['pclass'].value_counts()
plt.pie(pclass.values, labels=pclass.index)
plt.title('pclass pie')

plt.show()
```

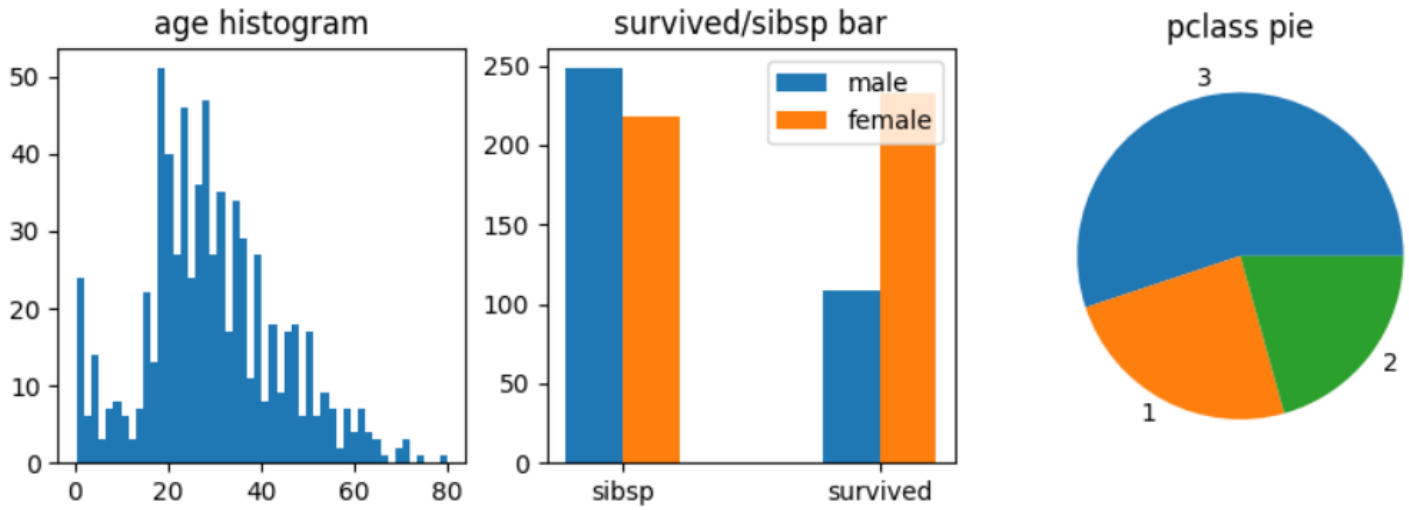

Для отображения независимых графиков в одном окне можно воспользоваться методом:

plt.subplot(*<кол-во строк>, <кол-во столбцов>,<ячейка в которой будет график>*)

Pandas plot()

Объекты Pandas (DataFrame, Series) имеют встроенные методы для рисования графика (на базе matplotlib): plot(), hist(), boxplot().

Метод plot() в свою очередь позволять построить различные виды графиков (через параметр kind=):

- ‘area’ – график с накоплением
- ‘bar’ – вертикальная гистограмма
- ‘barh’ – горизонтальная гистограмма
- ‘box’ – столбчатая диаграмма
- ‘hexbin’ – шестнадцатеричный график
- ‘hist’ – гистограмма
- ‘kde’ – оценка плотности ядра
- ‘density’ = ‘kde’
- ‘line’ – линейный график
- ‘pie’ – круговая диаграмма
- ‘scatter’ – график рассеяния

Набор параметров функции plot() зависит от типа графика.

Чаще всего это удобнее, чем использовать исходный синтаксис matplotlib, особенно для быстрого взгляда на данные, т.к. визуализация может быть настроена в одну строчку:

```
df.fare.plot(figsize=(5,1))
```

```
<Axes: >
```

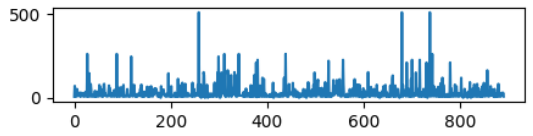


```
df['age'].hist(figsize=(3,3), bins=50)
plt.xlabel('Возраст')
plt.title('Гистограмма')
plt.show()
```

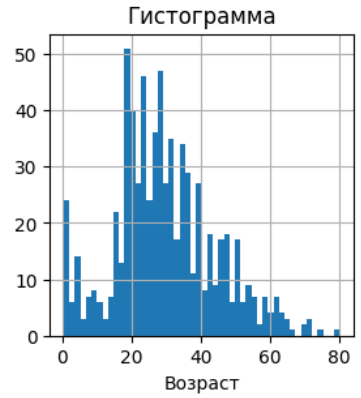


```
df[['fare', 'age']].plot(figsize=(5,3))
plt.title('Совмещенный график')
plt.show()
```

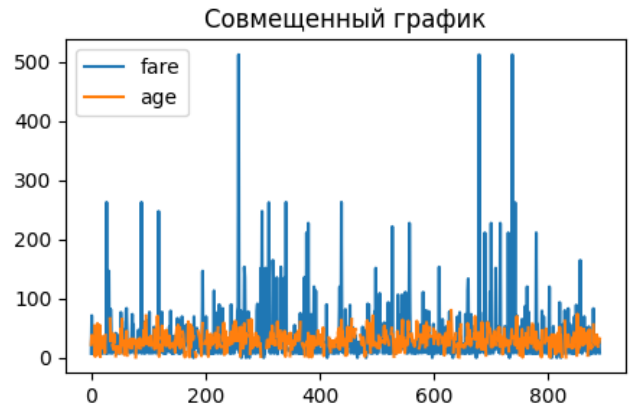


```
df['alive_num'] = df['alive']=='yes'
df.groupby('sex')[['sibsp', 'survived', 'alone', 'alive_num']].sum().T.plot.bar(figsize=(5,3))
```

```
<Axes: >
```

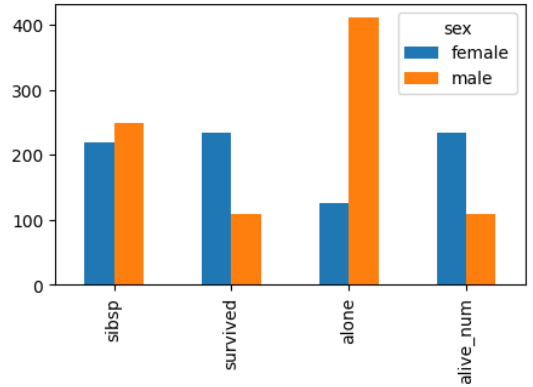

http://cs.petrsu.ru/~musen/python/prezent_pdf/lecture_7.html

Уральский федеральный университет

Seaborn

Seaborn – пакет для визуализации данных в Python (на базе matplotlib), красивее и синтаксически проще, чем matplotlib.

import seaborn as sns

В отличие от matplotlib здесь не нужно прописывать отдельные конструкции, все атрибуты задаются в параметрах функции.

Основные методы:

- *sns.barplot(x)* – столбчатая диаграмма
- *sns.heatmap(x)* – тепловая карта
- *sns.scatterplot(x, y)* – диаграмма рассеяния
- *sns.FacedGrid(df)* – связанные графики
- *sns.boxplot(x)* – диаграмма размаха
- *sns.violinplot(x)* – скрипичная диаграмма
- *sns.pairplot(x)* – парный график
- *sns. histplot*(x) – гистограмма
- *sns. displot*(x) – оценка распределения вероятностей

Seaborn хорошо использовать там, где нужны более красивые и информативные графики, например, для презентации или для более глубокого анализа.

```
plt.figure(figsize=(4, 3))
sns.barplot(x="class", y="survived", hue="sex", data=df)
```

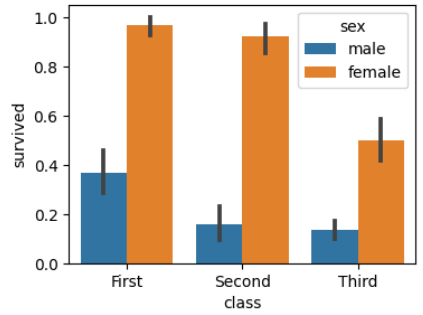


```
plt.figure(figsize=(4, 3))
sns.scatterplot(df['fare'])
```

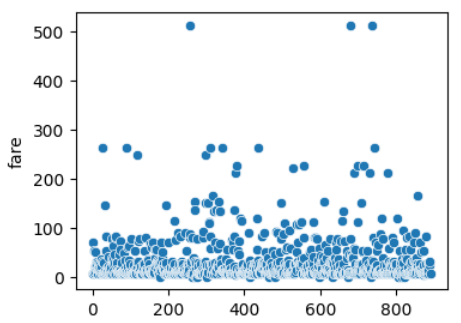


```
plt.figure(figsize=(4, 3))
sns.boxplot(df[['fare','age']])
```

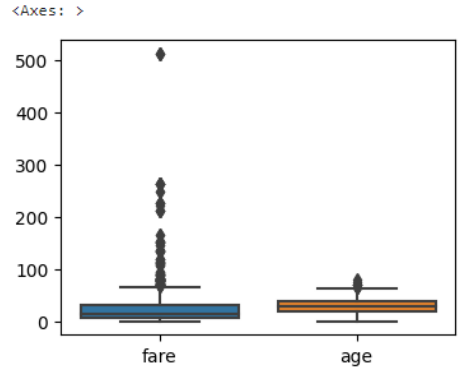


```
plt.figure(figsize=(4, 3))
sns.violinplot(df['age'])
```

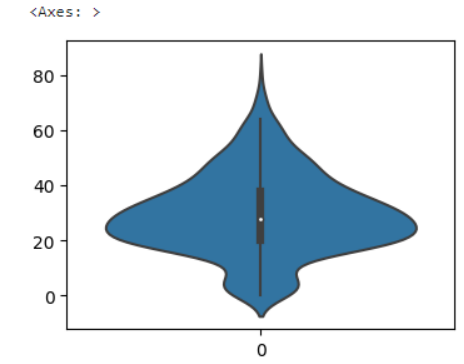

Уральский федеральный университет

Матрица корреляций

seaborn

Матрица корреляций хорошо помогает при оценке взаимосвязей между переменными.

Для вычисления самой матрицы обычно применяется метод corr() /pandas, а для отображения – встроенные функции pandas или тепловая карта (heatmap()) из sns: sns.heatmap(df.corr())

На пересечении соответствующего столбца и строки находится значение коэффициента корреляции этих двух переменных.

```
plt.figure(figsize=(4, 3))
sns.heatmap(df[['age','fare','pclass']].sort_values('age').corr(),
            cmap="YlGnBu",
            annot=True)
```

```
<Axes: >
```

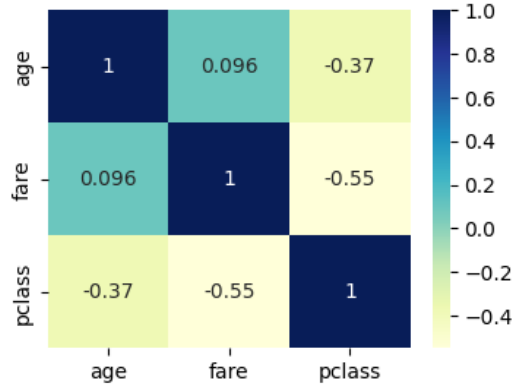


```
sns.heatmap(df[cont_columns].corr())
```

```
<Axes: >
```

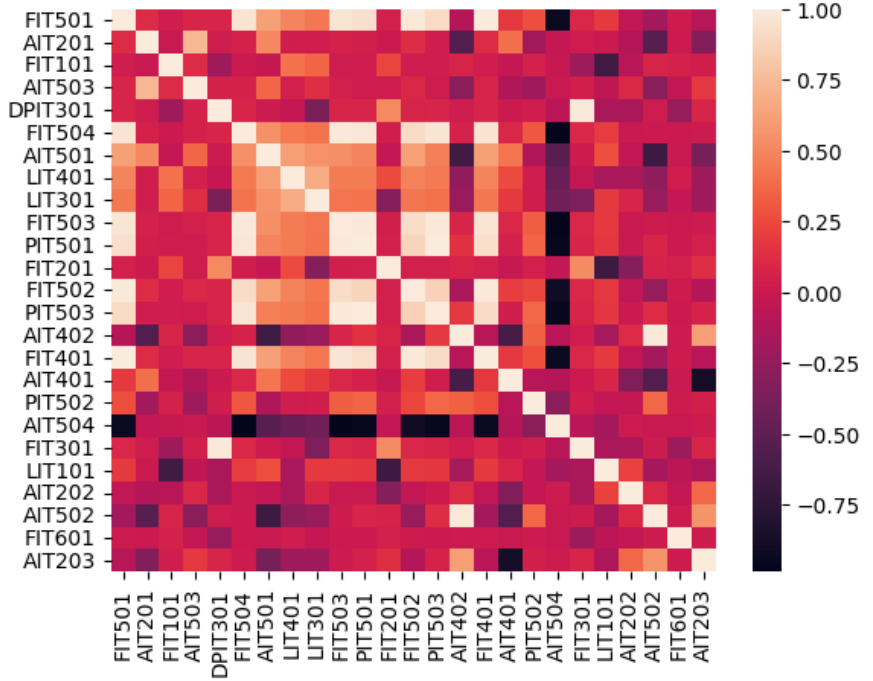

Уральский федеральный университет

Plotly

plotly | Graphing Libraries

plotly – библиотека для визуализации данных, в т.ч. интерактивной.

import plotly

Plotly очень функциональная, но из-за этого не очень легкая библиотека, поэтому для нее существуют различные модули.

Например, модуль plotly.express или cufflinks для визуализации данных Pandas.

cufflinks – модуль для упрощенной визуализации данных Pandas с использование Plotly.

import cufflinks

Для отображения графика вместо стандартного df.plot() для датафрейма нужно использовать df.iplot().

```
import cufflinks
df[['fare', 'age']].iplot(title='Интерактивный график', xTitle='id')
```

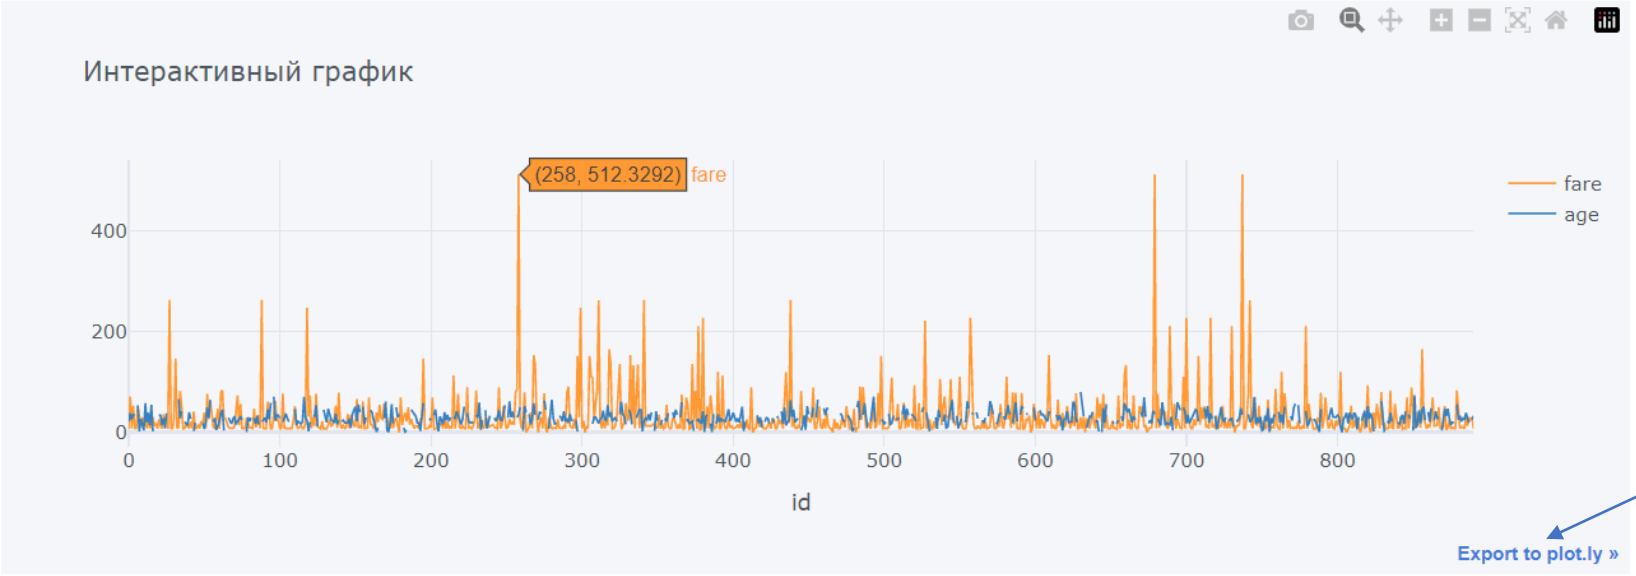

Также можно выгрузить данные в облако и очень удобно поиграть с ними там, выбирая различные представления, настройки и т.п.

Уральский федеральный университет

Итого

Вид анализа	Цель	Инструменты
Описательный (descriptive)	Количественное описание основных характеристик выборки.	Pandas в большинстве случаев достаточно
Разведывательный (exploratory, EDA)	Нахождение общих закономерностей, инсайтов, распределений, выбросов в данных.	Pandas для основных задач, SciPy (Numpy) для математических вычислений, для интерактивной визуализации – Plotly, для красивой – Seaborn
Индуктивный (inferential)	Оценка генеральной совокупности на основании выборки, выявление и оценка причинно-следственных связей между переменными.	Pandas или Numpy
Прогностический (predictive)	Предсказать поведение данных в будущем на основании их прошлых значений.	Библиотеки машинного обучения (про это в следующем курсе)
Причинно-следственный (causal)	Объяснение с точки зрения данных причин возникновения события (следствия).	Библиотеки машинного обучения (про это в следующем курсе)

Пока все.